Politechnika Warszawska

WYDZIAŁ MATEMATYKI
I NAUK INFORMACYJNYCH

Praca dyplomowa magisterska

na kierunku Informatyka

w specjalności Metody sztucznej inteligencji

Zestawienie technik uczenia maszynowego i heurystyk zastosowanych do proceduralnego generowania poziomów w grze Sokoban

Patryk Fijałkowski

Numer albumu 286350

promotor

dr inż. Maciej Bartoszuk

WARSZAWA 2021

....

podpis promotora

....

podpis autora

Streszczenie

Zestawienie technik uczenia maszynowego i heurystyk zastosowanych do proceduralnego generowania poziomów w grze Sokoban

Celem pracy jest zaproponowanie i wszechstronne porównanie czterech technik, które zostaną zastosowane do proceduralnego generowania poziomów w grze *Sokoban*.

W pracy zostanie sprawdzone, jak konfigurowalne są poszczególne metody pod kątem trudności i rozmiaru poziomu. Zostaną zbadane czasy uczenia w przypadku uczenia głębokiego i algorytmów genetycznych oraz czasy generowania poziomów przez każdą z testowanych metod. Przy użyciu odpowiednich metryk zostanie również określone, jak skomplikowane poziomy mogą zostać wygenerowane przez prezentowane techniki. *Sokoban* jest prostą grą łamigłówkową, w której gracz ma za zadanie przemieścić przedmioty w wyznaczone miejsca na planszy będącej prostokątną siatką, gdzie każde pojedyncze pole jest kwadratem. Trudność gry jest zależna od rozmieszczenia przedmiotów i przeszkód na planszy (poziomie). Zastosowanie proceduralnego generowania poziomów ma na celu odciążyć twórcę gry z wymyślania ich. Ponadto, generowanie proceduralne może potencjalnie tworzyć poziomy znacznie bardziej zawiłe niż człowiek.

Większość opisywanych w literaturze technik wymaga zebrania pewnej liczby gotowych plansz, opracowania odpowiedniej metody przechowywania najważniejszych elementów takich plansz w formie cech, a następnie tak spreparowane dane zasilają techniki uczenia maszynowego, które następnie są w stanie nauczyć się, jakimi właściwościami powinna się cechować dobrze zaprojektowana plansza i generować je samemu. Poza technikami z działu uczenia maszynowego zostanie również zaprezentowana heurystyka oparta na wiedzy eksperckiej, co pozwoli na zestawienie podejścia heurystycznego z uczeniem maszynowym.

Słowa kluczowe: Generowanie proceduralne, sztuczna inteligencja, heurystyka, *Sokoban*, uczenie maszynowe

Abstract

Comparison of machine learning techniques and heuristics used for procedural level generation in Sokoban game

TODO

Keywords: Procedural content generation, artificial intelligence, heuristics, Sokoban

Warszawa, dnia .....

Oświadczenie

Oświadczam, że pracę magisterską pod tytułem „Zestawienie technik uczenia maszynowego i heurystyk zastosowanych do proceduralnego generowania poziomów w grze Sokoban", której promotorem jest dr inż. Maciej Bartoszuk, wykonałem samodzielnie, co poświadczam własnoręcznym podpisem.

.....

Spis treści

1. Wstęp

Generowanie proceduralne to tworzenie zawartości przy użyciu algorytmów. Zamiast tworzyć zawartość, można to zadanie zlecić wyspecjalizowanym metodom. Wykorzystanie komputerów do generacji proceduralnej może przynieść więcej treści o wyższej jakości niż ludzka kreacja manualna, dlatego w dobie dynamicznego rozwoju technologii jest to istotne zagadnienie. Wśród licznych przykładów wykorzystania generacji proceduralnej warto wymienić oprogramowanie *Massive* [18], które generowało tłumy setki tysięcy postaci w bitwach z filmowej trylogii *Władcy Pierścieni* czy też *Terragen* [19], przy wykorzystaniu którego artyści i fotografowie dodają głębi przedstawianym krajobrazom.

1.1. Proceduralne generowanie zawartości w grach

Podczas tworzenia gier, zatrudniani są ludzie odpowiedzialni za tworzenie grafik, animacji czy projektowania poziomów. Zamiast tego, można posiłkować się odpowiednimi technikami do wygenerowania potrzebnego rodzaju zawartości.

Mówi się o zastosowaniu generowania proceduralnego w grach różnych gatunków. Zgodnie z [17], jest to technika powszechnie stosowana, która została zapoczątkowana w roku 1978, wraz z wydaniem *Beneath Apple Manor*. W tej produkcji zadaniem gracza jest sukcesywne przemierzanie kolejnych pokojów podziemnego świata, pokonując napotkanych na swojej drodze wrogów. Twórcy *Beneath Apple Manor* stworzyli algorytm generujący losowe pokoje, złożone z losowych kombinacji wrogów. Takie rozwiązanie powoduje, że każda rozgrywka będzie inna, tym samym stawiając przed graczem różne wyzwania.

Koncept proceduralnego generowania zawartości jest odciążeniem twórców gier. Coraz powszechniejsze staje się wykorzystywanie technik uczenia maszynowego w tym celu, co wykazano w rozdziale 1.1.1. Istnieją jednak pewne obostrzenia z tym związane, na przykład czasowe. Większość dzisiejszych gier zapewnia graczom wysokie odświeżanie ekranu. Za standard uznaje się gry generujące 120 klatek na sekundę (TODO - cytat). To oznacza, że na obliczenia związane z każdą klatką, można przeznaczyć co najwyżej 8 milisekund. Większość prezentowanych metod,

korzystających z uczenia maszynowego, nie jest w stanie w tak krótkim czasie generować dobrej jakości zawartości (TODO - runtime).

1.1.1. Przykłady

Interesującym zastosowaniem uczenia maszynowego w generacji proceduralnej jest gra *Galactic Arms Race* [12] wydana w 2014 roku przez *Evolutionary Games*. Twórcy posiłkowali się autorskim algorytmem genetycznym, tworząc różne konfiguracje pocisków statków kosmicznych, takich jak na rys. 1.1. Algorytm *cgNEAT* [12] ewoluuje, mając na uwadze preferencje użytkownika, które są określane na bieżąco podczas rozgrywki. Oznacza to, że twórcy nie musieli kreować działania i graficznych aspektów pocisków – ta zawartość była tworzona przez algorytm.

Rysunek 1.1: Zrzut ekranu z gry *Galactic Arms Race*,
źródło: http://indiedb.com

W grze *Spelunky* zadaniem gracza jest przemierzanie kolejnych poziomów, co wymaga zręczności i szybkiego podejmowania decyzji. Twórcy *Spelunky* zdecydowali się na rozwiązanie hybrydowe w kontekście generowania poziomów, co zostało dokładnie opisane w [15]. Algorytm jest heurystyką, która działa w oparciu o podział poziomu na 16 części, jak na rys. 1.2a. Każda z nich jest tworzona na podstawie szablonu (ang. *template*), których zbiór został stworzy przez projektantów. Algorytm poprawia tak stworzony poziom, dodając element losowości i zapewniając, że istnieje ścieżka od wejścia do wyjścia z poziomu.

Generacja proceduralna nie jest techniką stosowaną wyłącznie w nowych grach. Autorzy [16] wykorzystali generatywne sieci współzawodniczące (ang. *Generative Adversarial Networks*) do tworzenia nowych poziomów w kultowej grze *Super Mario Bros.*

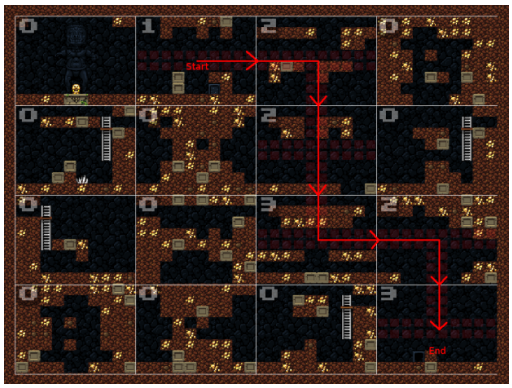

(a) Poziom w *Spelunky*

(b) Poziom w *Super Mario Bros.*

Rysunek 1.2: Poziomy w grach korzystających
z generacji proceduralnej, źródła: [15], [16]

1.2. Sokoban

Sokoban jest grą logiczną, rozgrywaną na planszy złożonej z kwadratów. Celem gracza jest przesunięcie wszystkich pudeł w wyznaczone kwadraty docelowe, tak jak na rysunku 1.3b. Zaczynając z planszą jak na rysunku 1.3a, gracz musi wykonać co najmniej 8 ruchów, w tym 4 pchnięcia pudeł. Jednak istnieje też rozwiązanie tej planszy, wykorzystujące 12 ruchów, w tym 2 pchnięcia. Różne implementacje gry uznają liczbę ruchów albo liczbę pchnięć jako ocenę rozwiązania.

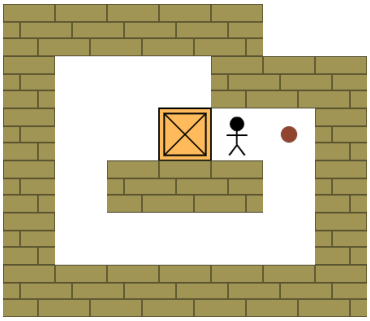

(a) Plansza początkowa

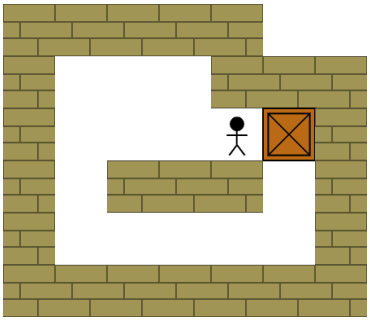

(b) Plansza końcowa

Rysunek 1.3: Przykładowa plansza *Sokoban*

Oryginalnie *Sokoban* jest grą wideo autorstwa Hiroyuki Imabayashi, wydaną w 1982 roku na platformę PC-88. Od tamtego czasu koncepcja gry jest rozwijana i implementowana w innych grach, takich jak *Pokémon Emerald* czy *Grand Theft Auto: San Andreas*. Ponadto, użytkownicy tworzą coraz bardziej skomplikowane plansze, czego dowodem są zbiory wymienione w tabeli 1.1.

Tabela 1.1: Zbiory plansz Sokoban, źródło: [26]

Nazwa zbioru	**Liczba poziomów**
Sven	1911
Sasquatch I-VII	350
Sokoban Perfect	306
Sokoban Revenge	306
Aymeric	282
SokHard	163

1.2.1. Rozwiązanie

Zgodnie z [13], problem podania rozwiązania czy choćby ustalenia, czy zadana plansza *Sokoban* jest rozwiązywalna, jest problemem *PSPACE*-zupełnym. Problemy *PSPACE*-zupełne to grupa problemów, które mogą zostać rozwiązane przy użyciu maszyny Turinga, wykorzystując wielomianową ilość pamięci, ale nie są problemami NP.

Drzewo decyzyjne odpowiadające rozgrywce, mimo swojego niskiego współczynnika rozgałęzienia (ang. *braching factor*), jest wysokie. W przypadku rozwiązywania planszy *Sokoban*, omawiany współczynnik wynosi co najwyżej cztery, ponieważ w każdej sytuacji gracz może dokonać ruchu w jednym z czterech kierunków.

W związku z tym, powstają heurystyczne *solvery*, które potrafią rozwiązywać plansze *Sokoban* w czasie wielomianowym [26]. Mimo to, odnosząc się do raportu prezentowanego na [26], nie powstał jeszcze *solver*, który rozwiązywałby poprawnie wszystkie plansze z badanego zbioru.

Problem rozwiązania planszy *Sokoban* jest powiązany z wieloma metodami generacji plansz. Metody generujące, które nie opierają swojego działania na zasymulowaniu rozgrywki, potrzebują na różnych etapach swojego działania weryfikować, czy aktualnie tworzona plansza jest rozwiązywalna. Jako że sprawdzenie tego w sposób dokładny nie jest możliwe czasowo, w tym celu również wykorzystywane są heurystyczne *solvery*.

2. Prezentacja metod

W niniejszej pracy zdecydowano się zestawić cztery metody generowania poziomów Sokoban, pogrupowanych w tabeli 2.1. Dogłębna analiza metod proponowanych w literaturze dla problemu generowania poziomów Sokoban pozwoliła na dobór reprezentatywnych metod. Wybrano dwie będące heurystykami, które nie korzystają z technik uczenia maszynowego, oraz dwie – korzystające. Ponadto, dobrano dwie, które bazują na symulacji rozgrywki oraz dwie, które działają bez symulowania działań gracza.

Istotną zaletą analizowanych metod, które symulują rozgrywkę, jest możliwość podania przykładowej sekwencji ruchów, rozwiązujących daną planszę – tej z symulacji. Z kolei metody, w których nie symuluje się rozgrywki, mogą zostać zastosowane do innych problemów niż generowanie plansz *Sokoban*, ze względu na swoje uogólnienie analizowanego problemu. Autorzy [4] wprowadzają swoją metodę, stosując ją jeszcze do generowania plansz dwóch innych rodzajów. Autorzy [2] podkreślają, że ich metodę generacji można zaadaptować do każdego problemu, który da się sprowadzić do postaci opisanej w rozdziale 2.2.1.

Tabela 2.1: Analizowane metody

	Heurystyka	**Uczenie maszynowe**
Symulacja rozgrywki	SYM [1]	MCTS [3]
Brak symulacji	PDB [2]	PPO [4]

2.1. Metoda SYM

Metoda SYM [1], opiera swoje działanie na symulowaniu zmodyfikowanej rozgrywki *Sokoban*. Iteracyjnie wykonując pewne akcje i przechodząc po początkowo pustej planszy, agent wyznacza wolne pola na planszy.

2.1.1. Opis metody

Metoda SYM rozpoczyna pracę, losując początkowe ustawienia pudeł na planszy. Następnie agent wykonuje założoną liczbę razy dwa rodzaje rozgrywek: najpierw rozgrywki typu *forward*, a następnie – *backward*, by potem uporządkować generowaną planszę.

W rozgrywce *forward*, agent wybiera w określony sposób pudło i kierunek jego przepychania, by dokonać przepchnięcia. Jeśli przepchnięcie jest możliwe, to pudło zmienia swoją pozycję, a pola przez które przeszedł agent, stają się pustymi polami. Przykładowo, jeśli dla planszy na rys. 2.1a gracz wybierze wyższe pudło i dół jako kierunek przepychania, to jego akcja spowoduje że plansza przybierze układ jak na rys. 2.1b.

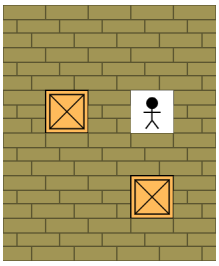

(a) Plansza przed wykonaniem akcji

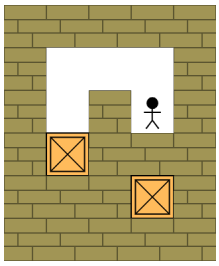

(b) Plansza po wykonaniu akcji

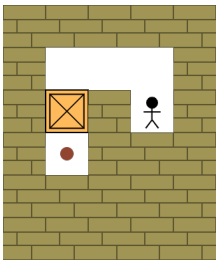

(c) Plansza po zakończeniu rozgrywki

Rysunek 2.1: Działanie akcji w rozgrywce *forward*

Po zakończeniu rozgrywki *forward*, pudła zamieniane są w pola docelowe, a startowe pozycje pudeł stają się faktycznymi pudłami. Ponadto, nieprzepchnięte pudła zamieniane są w ściany. Kontynuując analizę przypadku, jeśli rozgrywka *forward* zostanie zakończona z planszą jak na rys. 2.1b, to w wyniku transformacji otrzyma się planszę przedstawioną na rys. 2.1c i agent przejdzie do przeprowadzenia rozgrywki *backward*, w celu dodatkowego skomplikowania planszy.

W rozgrywce *backward*, agent wybiera w określony sposób pudło i kierunek jego przeciągania, by dokonać przeciągnięcia. Jeśli przeciągnięcie jest możliwe, to pudło oraz gracz aktualizują swoje pozycje. Przykładowo, jeśli dla planszy na rys. 2.2a gracz wybierze jedyne dostępne pole docelowe i lewo jako kierunek przepychania, to jego akcja spowoduje że plansza przybierze układ jak na rys. 2.2b.

(a) Plansza przed wykonaniem akcji

(b) Plansza po wykonaniu akcji

Rysunek 2.2: Działanie akcji w rozgrywce *backward*

2.1.2. Strategie

Wybór pudła	**Kierunek przepychania**	**Kierunek przeciągania**	**Wybór ścieżki**
Random	*Random*	*Random*	*Direct*
Least Pushed	*Farthest*	*Farthest*	*Closest Active Tile*
In Order	*Most Obstacles*	*Most Obstacles*	
		Most Access	

Tabela 2.2: Strategie decyzyjne metody SYM

W procesie generowania planszy metody SYM, agent podejmuje decyzje o przepychaniu i przeciąganiu pudeł oraz o sposobie wyboru ścieżek. Wybory dokonywane są zgodnie z ustalonymi wcześniej strategiami, będącymi hiperparametrami metody, które zostały zaprezentowane w tab. 2.2. Strategie *Random* dokonują wyborów w sposób losowy. Strategia *Least Pushed* wybiera te pudła, które w momencie podejmowania decyzji zostały przepchnięte najmniejszą liczbę razy, a *In Order* – wybiera pudła po kolei, niezależnie od liczby przepchnięć. *Farthest* maksymalizuje odległość od pudła do jego pola docelowego. *Most Obstacles* wybiera kierunek tak, by wynikowa pozycja pudła sąsiadowała z jak największą liczbą ścian i innych pudeł. *Most Access* ma zapewnić agentowi jak najwięcej dostępnych kierunków po wykonaniu akcji przeciągania. Strategia wyboru ścieżek *Closest Active Tile* stara się wykorzystać jak najwięcej już

odwiedzonych pól, zachowując w ten sposób więcej ścian niż jej odpowiadająca strategia *Direct*, która wybiera najkrótsze możliwe ścieżki.

2.2. Metoda PDB

Autorzy [2] wprowadzają metodę PDB, bazując na teorii problemu przeszukiwań przestrzeni stanu (ang. *state-space search problem*) oraz baz danych wzorców (ang. *pattern databases*).

2.2.1. Problem przeszukiwań przestrzeni

Problemem przeszukiwań przestrzeni stanu nazywa się krotkę opisaną w równaniu 2.1. Składowe problemu to kolejno zbiór stanów S, stan początkowy s_0, zbiór stanów docelowych S^* oraz zbiór akcji A. Stan definiuje się jako pełne przypisanie wartości wszystkim zmiennym $v \in V$, przy zachowaniu dziedzin D_v. Rozwiązaniem problemu przeszukiwań przestrzeni jest ścieżka rozwiązująca (ang. *solution path*) – skończony ciąg akcji, po wykonaniu którego ze stanu s_0 otrzyma się stan ze zbioru S^*.

$$\mathcal{P} =< S, s_0, S^*, A > \tag{2.1}$$

Opisywany problem różni się od innych problemów przeszukiwania tym, że przestrzeń stanów jest niejawna (ang. *implicit*). W prezentowanym rozwiązaniu, graf przestrzeni stanów jest zbyt duży, aby można go było wygenerować i przechowywać w pamięci. Zamiast tego, jedynie interesujące węzły są generowane i robione jest to na bieżąco – w trakcie ich eksploracji. Stanami w metodzie PDB są przypisania lokalizacji k pudeł i gracza, a więc składają się z $k+1$ zmiennych. Dziedziną każdej zmiennej są puste pola. W związku z tym, liczba możliwych stanów opisana jest wzorem $(n-k)\binom{n-k-1}{k}$, gdzie n to liczba wolnych pól. Już dla mało skomplikowanej planszy przedstawionej na rys. 2.3 istnieje więc 595 980 możliwych stanów (wierzchołków grafu).

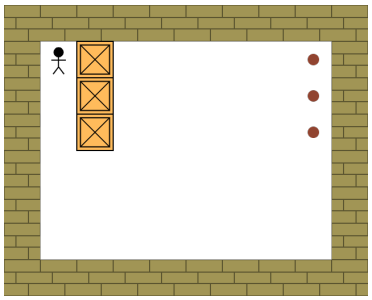

Rysunek 2.3: Przykładowa plansza o rozmiarze 8 x 10

Autorzy [2] definiują ponadto problem wygenerowania początkowego stanu (ang. *initial state generation task*) $\mathcal{P}_{-s_0}$, opisany krotką w równaniu 2.2. Jest on równoważny problemowi przeszukiwań przestrzeni ze stanem początkowym s_0, jednak celem nie jest wyznaczenie ścieżki, a

wskazanie stanu $s \in S$, dla którego problem $\mathcal{P}_{-s_0}$ z s jako stanem początkowym, jest rozwiązywalny.

$$\mathcal{P}_{-s_0} =< S, S^*, A > \tag{2.2}$$

2.2.2. Bazy danych wzorców

W celu rozwiązania problemu opisanego w 2.2.1, stosuje się heurystykę bazy danych wzorców, wprowadzoną przez Josepha Culbersona oraz Jonathana Schaeffera w [9]. Idea tej heurystyki oparta jest na zignorowaniu części problemu (podzbioru zmiennych V) i wyznaczenie dolnego ograniczenia długości ścieżki optymalnej dla każdego stanu uproszczonego problemu.

TODO - algorytm, jak się z tego korzysta

2.2.3. Opis metody

Metoda PDB, nazywana przez autorów [2] algorytmem β, rozwiązuje problem opisany wzorem 2.2 w oparciu o podejście zachłanne. W tym celu wykorzystywane jest przeszukiwanie grafu wstecz, które priorytetyzuje węzły o najbardziej obiecującej wartości heurystyki (ang. *best-first search*). Graf stanów jest przeszukiwany wstecz, od wierzchołków odpowiadającym stanom docelowym, co gwarantuje istnienie ścieżki docelowej. Autorzy [2] podkreślają, że przeszukiwanie grafu od wierzchołka początkowego s_p wymagałoby zapewnienia o istnieniu ścieżki docelowej rozpoczynającej się w s_p, co jest wymagające obliczeniowo.

Podczas eksploracji, algorytm korzysta z funkcji nowości (ang. *novelty function*), opisanej w [14].

$$novelty(s) \tag{2.3}$$

TODO: Funkcja nowości

2.3. Metoda MCTS

Autorzy [3] wprowadzają metodę MCTS jako autorską adaptację heurystyki *Monte-Carlo Tree Search*.

2.3.1. Wprowadzenie

Monte-Carlo Tree Search jest heurystyką, której celem jest podejmowanie decyzji w pewnych zadaniach sztucznej inteligencji. Metoda opiera swoje działanie na przeszukiwaniu możliwych stanów zapisanych w wierzchołkach drzewa i losowym symulowaniu rozgrywek. Algorytmy z grupy MCTS opierają się na iteracyjnym rozbudowywaniu drzewa stanów przez sekwencyjne wykonanie czterech faz – selekcji, ekspansji, symulacji i propagacji wstecznej. Poszczególne fazy zostały zobrazowane na rys. 2.4.

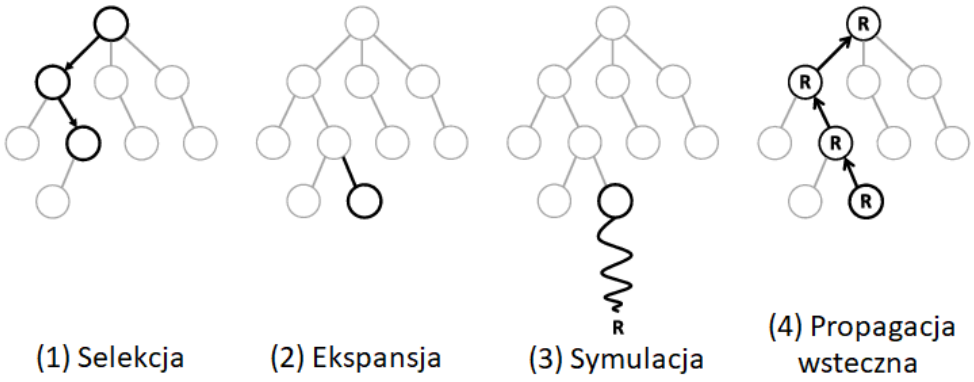

Rysunek 2.4: Fazy MCTS, źródło: [5]

Faza selekcji w heurystyce *Monte-Carlo Tree Search* pozostawia dowolność w wyborze liścia, który będzie eksploatowany w kolejnych fazach. Oczywiście sposób wybierania liści w kolejnych iteracjach jest krytyczny z punktu widzenia eksploracji drzewa i działania metody. W literaturze opisywane są różne podejścia, przykładowo UCB_Minimal w [6], czy UCB-V w [7]. Najbardziej powszechny i użyty w metodzie MCTS jest jednak wariant UCT, opisany w [8]. Ten wariant stara się zachować równowagę między eksploatacją bardziej obiecujących ruchów a eksploracją tych rzadko odwiedzonych. Formuła, która odpowiada za wyznaczenie najbardziej obiecującego wierzchołka w fazie wyboru MCTS jest przedstawiona jako wyrażenie (2.4). Indeks i odnosi się do liczby wykonanych przez algorytm iteracji, czyli czterech faz MCTS. W pierwszym składniku sumy wyrażenia (2.4), licznik w_i oznacza sumę wszystkich wypłat w danym węźle, a mianownik n_i oznacza liczbę rozegranych symulacji. Parametr eksploracji c, może być dostosowany do badanego problemu. Odwołując się do [8], dla problemu z wypłatami w przedziale $[-1, 1]$, optymalnie jest przyjąć $c = \sqrt{2}$.

$$\frac{w_i}{n_i} + c\sqrt{\frac{\ln\left(\sum_i n_i\right)}{n_i}} \tag{2.4}$$

2.3.2. Opis metody

Metoda MCTS opiera swoje działanie na symulowaniu zmodyfikowanej rozgrywki Sokoban, która składa się z dwóch faz. W pierwszej gracz ma do wyboru trzy akcje: może usuwać przeszkody graniczące z pustymi polami, stawiać pudła lub zamrozić planszę. Algorytm zaczyna pracę z planszą w pełni wypełnioną przeszkodami, więc zadaniem fazy pierwszej jest przygotowanie pustych pól. W wyniku akcji zamrożenia, rozgrywka przechodzi do fazy drugiej, w której gracz prowadzi normalną rozgrywkę, poruszając się i przesuwając pudła, do momentu aż zdecyduje się ją zewaluować. Ewaluacja jest akcją, która kończy rozgrywkę i dokonuje dodatkowych procesów czyszczenia w celu uzyskania maksymalnie dobrej i poprawnej planszy.

Kluczowe dla metody MCTS jest dobranie funkcji oceniającej jakość generowanych poziomów. Jako że *Monte-Carlo Tree Search* opiera swoje działanie na wielokrotnym symulowaniu rozgrywek, wyznaczanie wypłaty dla danego poziomu musi być mało kosztowne obliczeniowo. Autorzy [3] zdecydowali się na funkcję opisaną wzorem 2.5, która jest sumą ważoną trzech metryk, podzieloną przez stałą z, dla znormalizowania wyniku. Wyrazy w_b, w_c i w_n są wagami dla odpowiednich metryk, opisanych poniżej.

1. Metryka pudeł 3 x 3 P_b - liczba pól, która nie znajduje się w bloku 3 x 3 przeszkód lub pustych pól. Zadaniem tej metryki jest nagrodzenie plansz, które nie zawierają bloków 3 x 3 tych samych pól, gdyż tego typu czynią plansze mniej skomplikowanymi.

2. Metryka zagęszczenia P_c - funkcja nagradzająca plansze o długich ścieżkach między pudłami a ich docelowymi punktami.

3. Metryka pudeł P_n - liczba pudeł na planszy.

$$\frac{w_b P_b + w_c P_c + w_n P_n}{z} \tag{2.5}$$

2.4. Metoda PPO

2.4.1. Opis metody

Metoda PPO [4] opiera swoje działanie na algorytmie *Proximal Policy Optimization* uczeniu ze wzmocnieniem. Autorzy dzielą schemat jej działania na trzy moduły: problemu (ang. *problem module*), reprezentacji (ang. *representation module*) i szansy zmiany (ang. *change percentage*), co zostało ukazane na schemacie z rys. 2.5. Dokładniejszy opis poszczególnych modułów został przedstawiony w rozdziale 2.4.2.

Agent na podstawie obserwacji aktualnego stanu S_t dokonuje akcji a_t, w wyniku czego moduł reprezentacji przekształca S_t w S_{t+1}. Wtedy moduł problemu wyznacza nagrodę r_{t+1}, zestawiając ze sobą oba stany. Potem do agenta przekazywane są S_{t+1} oraz r_{t+1} i pod warunkiem, że agent nie otrzymał informacji e_{t+1} o przekroczeniu dozwolonej liczby zmian, wykonywane są dalsze iteracje uczenia.

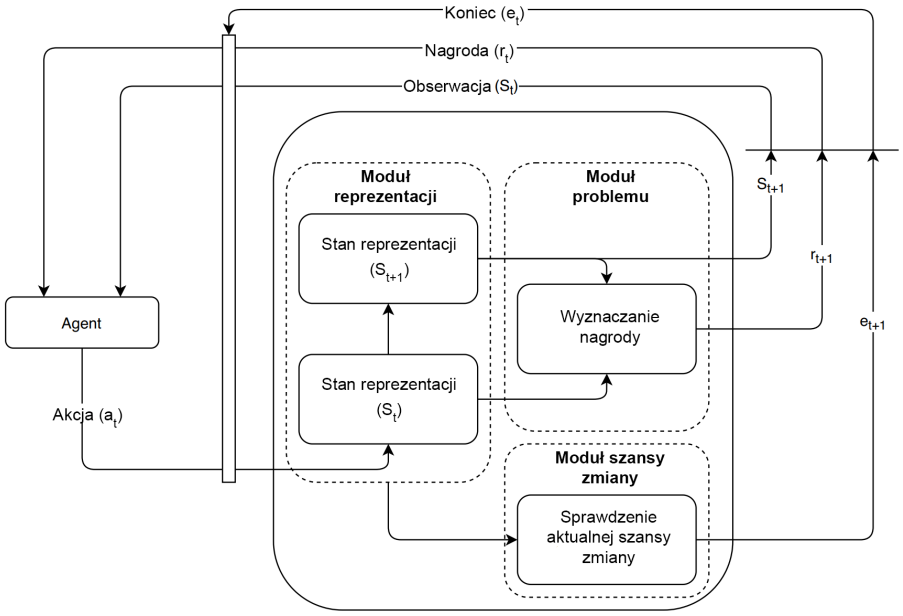

Rysunek 2.5: Schemat działania metody PPO, źródło: [4]

2.4.2. Moduły

Moduł problemu dostarcza informacji na temat rozmiaru planszy i dostępnych typów obiektów. Ten moduł ocenia też, jak akcje podejmowane przez agenta wpływają na jakość generowanych poziomów. Ponadto, zadaniem tego modułu jest też stwierdzenie, kiedy epizod uczenia powinien zostać zakończony.

Moduł reprezentacji inicjalizuje problem, przechowuje aktualny stan i modyfikuje go, bazując

na akcjach agenta. W prezentowanym zastosowaniu, każdej komórce na planszy odpowiada wartość z zakresu $[0, 6]$. Zaimplementowane są trzy różne reprezentacje, opisane poniżej. Najistotniejszą różnicą jest zasięg zmian w każdej reprezentacji – wąska ma z góry narzuconą sekwencję pól, żółwia na każdym kroku ma maksymalnie 4 dostępne, a szeroka ma pełną dowolność. Mówi się że reprezentacja szeroka ma globalny zasięg zmian w przeciwieństwie do reprezentacji wąskiej i żółwiej.

1. Wąska – na każdym kroku agent obserwuje aktualną planszę i pewną lokację na planszy. Może wtedy zamienić wartość komórki w zadanej lokacji, ale może też przejść do dalszych kroków bez tej zmiany.

2. Żółwia – na każdym kroku agent obserwuje aktualną planszę i lokację. Może zamienić wartość komórki w aktualnej lokacji albo przemieścić aktualną lokację w dowolne sąsiadujące z nią pole. Ten sposób reprezentacji jest inspirowany językami programowania Logo, w których użytkownik przemieszcza wirtualnego żółwia po planszy.

3. Szeroka - na każdym kroku agent obserwuje aktualną planszę i może zamieniać wartości komórek w dowolnych lokacji.

Moduł szansy zmiany ogranicza możliwość zmieniania dowolnych komórek na planszy, żeby agent nie wymienił wszystkich zadanych komórek, limitując tym samym długość jednego epizodu. Zgodnie z obserwacjami opisanymi w [4], agent o niskiej szansie zmiany wykonuje akcje zachłanne, maksymalizując wypłaty w krótkiej perspektywie, podczas gdy agent o wysokiej szansie zmiany zdaje się wyznaczać bardziej optymalne i długoterminowe plansze. Problemem z agentem o wysokiej szansie zmiany jest ryzyko dążenia do jednej, najbardziej korzystnej planszy, co nie jest celem tej metody. W tym przypadku agenta chce się nauczyć poprawiania zadanych plansz na lepsze.

2.4.3. Weryfikacja planszy

Opisany w rozdziale 2.4.2 moduł problemu weryfikuje poprawności generowanych plansz, przy użyciu naiwnego *solvera*, bazującego na przeszukiwaniu drzewa rozgrywki aż do 5000 wierzchołków. W celu wyszukiwania najkrótszej ścieżki, użyty został algorytm A*.

2.4.4. Implementacja

Implementacja, na bazie której przeprowadzono eksperymenty, została przygotowana w języku *Python* w wersji 3.5. Wykorzystano biblioteki *Stable Baselines* w wersji 2.9 oraz *OpenAI Gym* w wersji 0.7.4 udostępniające.

Agentowi aktualna plansza przedstawiana jest przy użyciu one-hot-encoding. Użyto dwóch różnych sieci neuronowych. Pierwsza z nich jest wykorzystana do reprezentacji żółwiej i wąskiej. Druga do reprezentacji szerokiej z powodu na istotnie większą przestrzeń dostępnych akcji.

1. Architektura 1 - złożona z trzech warstw konwolucyjnych i dwóch w pełni połączonych. Ta architektura bazowała na [21].

2. Architektura 2 - złożona z dziesięciu warstw konwolucyjnych i dwóch w pełni połączonych. Ta architektura bazowała na [22].

3. Wyniki eksperymentów

3.1. Maszyna testowa

Wszystkie eksperymenty zostały wykonane na komputerze:

- z zainstalowanym systemem operacyjnym *Windows 10 Education N*,
- wyposażonym w procesor *Intel Core i7-8700k @3.70 GHz*,
- wyposażonym w kartę graficzną *NVIDIA GeForce GTX 1060 6GB*,
- wyposażonym w 32GB pamięci RAM.

3.2. Metoda SYM

3.2.1. Wydajność czasowa

W celu zbadania wydajności czasowej metody SYM, wykonano eksperyment badający średni czas wykonania zadanej liczby iteracji *forward* oraz *backward*. W eksperymencie uwzględniono wszystkie możliwe konfiguracje strategii oraz rozmiary plansz z zakresu $[5, 30]$. Wyniki analizy, ukazane na rys. 3.1, wykazały iż średnio rozgrywka *forward* nie trwała dłużej niż 0.25 sekundy, a rozgrywka *backward* – 0.1 sekundy. Co więcej, dla liczby iteracji poniżej stu, generacja planszy zajmowała średnio mniej niż 0.122 sekundy.

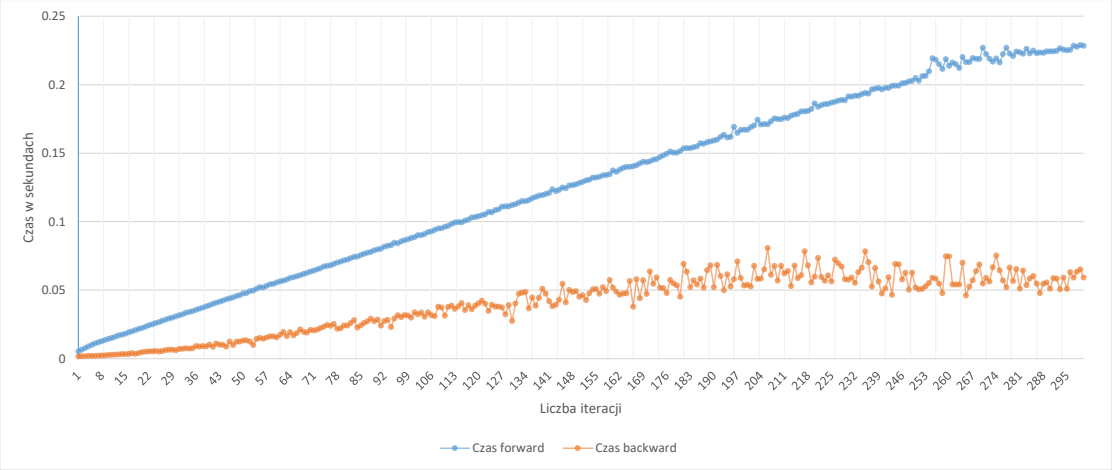

Rysunek 3.1: Zależność czasu od liczby iteracji

Autorzy metody SYM zestawiają wydajność czasową swojej metody z algorytmem zaprezentowanym w [27], który również jest metodą heurystyczną symulującą rozgrywkę. Metoda SYM wygrywa ze swoim odpowiednikiem przede wszystkim ze względu na niezależność od liczby pudeł na generowanej planszy. Metoda opisana w [27] dla liczby pudeł poniżej sześciu uzyskuje podobne wyniki, za to zależność czasu od liczby pudeł powyżej sześciu ma charakter wykładniczy. Co więcej, czas obliczeń odpowiednika metody SYM rośnie kwadratowo w zależności od wartości hiperparametru definiującego skomplikowanie plansz, czego nie obserwuje się w przypadku metody SYM. Analizując inne badania zaprezentowane w [1], można wnioskować iż jest to najbardziej wydajna czasowo opublikowana metoda heurystyczna generowania plansz *Sokoban*.

3.2.2. Liczba iteracji

Wraz ze zwiększaniem liczby iteracji *forward* w metodzie SYM, plansze zyskują coraz więcej pustych pól, co można zaobserwować na rys. 3.2. To oznacza, że zmniejsza się ich wypełnienie – stosunek niepustych pól do wszystkich pól na planszy. Autorzy [23] sugerują, że większość

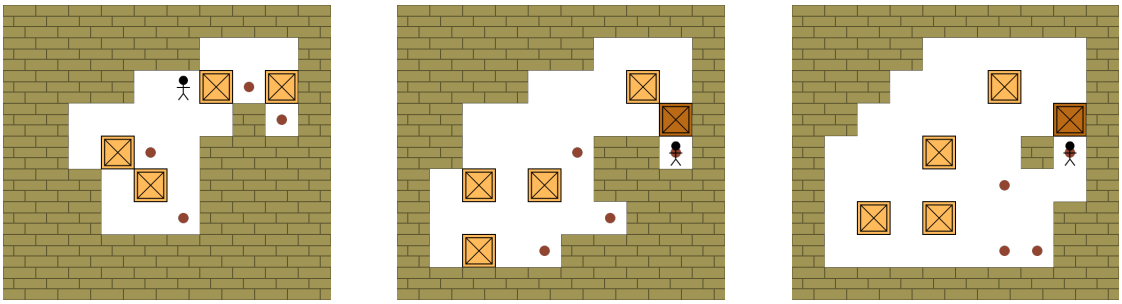

(a) Plansza po 4 iteracjach (b) Plansza po 10 iteracjach (c) Plansza po 30 iteracjach

Rysunek 3.2: Wpływ liczby iteracji *forward* na wypełnienie generowanych plansz

istotnie skomplikowanych plansz charakteryzuje się wypełnieniem na poziomie od 50% do 55%. Aby sprawdzić charakter wypełnienia dla analizowanej metody, dokonano generacji 5000 plansz rozmiaru $8x8$ z użyciem różnych kombinacji parametrów, dla określonego zakresu liczby iteracji *forward* i *backward*. Wyniki analizy zaprezentowano na rys. 3.3. Jak widać, dla tego rozmiaru planszy, żądane wypełnienie uzyskuje się dla liczby iteracji *forward* z zakresu $[17, 30]$. Liczba iteracji *backward* nie ma istotnego wpływu na wypełnienie generowanych plansz.

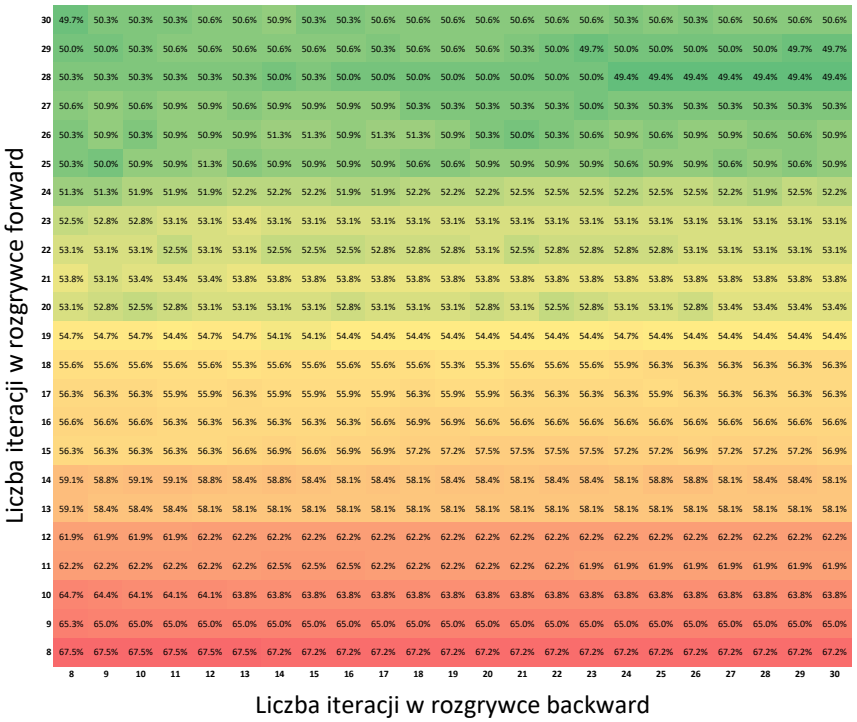

Rysunek 3.3: Zależność wypełnienia generowanych od liczby iteracji

Jako że samo wypełnienie nie jest gwarantem skomplikowania poziomów, postanowiono zbadać również zależność średniej sumy odległości pudeł od ich pól docelowych. Wykonano eksperyment analogiczny do poprzedniego, a jego wyniki zaprezentowano na rys. 3.4. Jak widać, niezależnie od użytej liczby iteracji *forward*, wraz ze wzrostem liczby iteracji *backward*, sumy

odległości rosły, czyniąc plansze bardziej skomplikowanymi. Dla niektórych przypadków, zwiększenie liczby iteracji *backward*, wydłużało sumę odległości o ponad 40%.

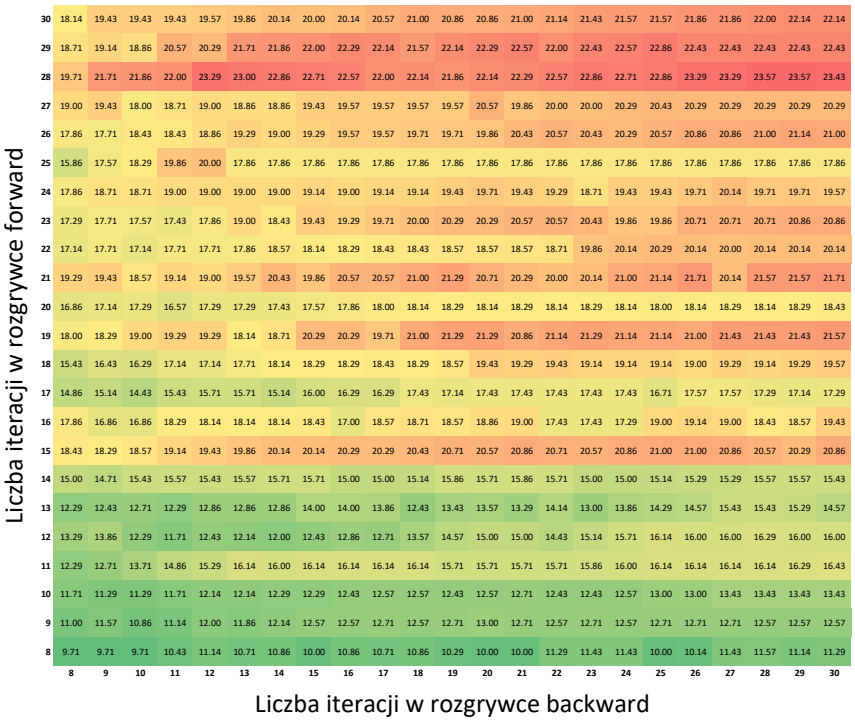

Rysunek 3.4: Zależność sumy odległości między pudłami a polami docelowymi od liczby iteracji

3.3. Metoda PDB

TODO

3.4. Metoda MCTS

Wartą przytoczenia jest praca [20], w której starano się usprawnić metodę MCTS. Zaprezentowano siedem usprawnień oryginalnej metody, jednak żadne z nich nie poprawiło jej na tyle, by generowane poziomy można było uznać za zadowalająco skomplikowane.

3.4.1. Wydajność czasowa

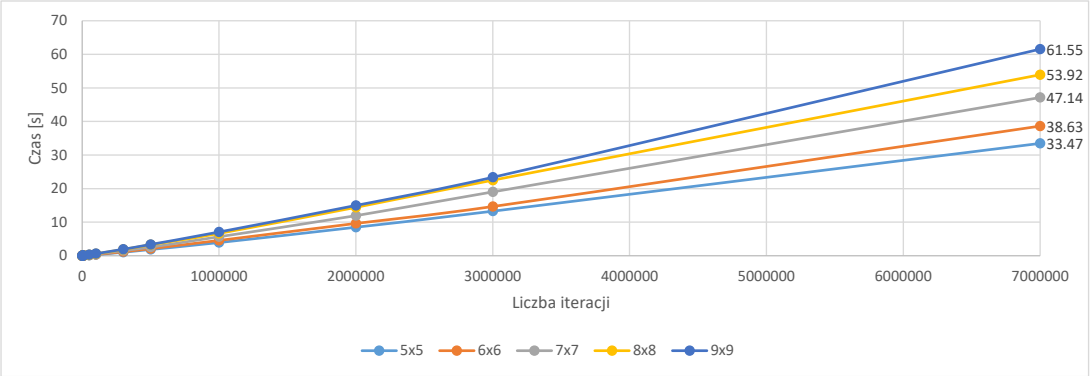

Rysunek 3.5: Zależność czasu od liczby iteracji

Wydajność czasowa metody jest najbardziej zależna od czasu rozegrania pełnej zmodyfikowanej rozgrywki. W prezentowanej implementacji liczba rozgrywek na sekundę jest zależna od rozmiaru planszy i spada wraz z ze wzrostem liczby iteracji. Dla plansz o boku krótszym niż sześć i liczby iteracji mniejszych od miliona, wykonywane jest aż do 300 000 trywialnych rozgrywek na sekundę. Ta wydajność spada prawie dziesięciokrotnie dla większych plansz i iteracji. W celu przełożenia tej wydajności na wartości czasowe, sporządzono wykres z rys. 3.5. Jak widać, dla siedmiu milionów iteracji metoda zakończy pracę po trzydziestu sekundach dla planszy o rozmiarze $5x5$, ale ta sama praca dla planszy $9x9$ zostanie wykonana po upływie minuty.

3.4.2. Ograniczenia

Zbadano ponadto zależność zużytej pamięci od liczby iteracji i maksymalnej liczby pudeł. Po przeanalizowaniu wyników eksperymentu, wnioskuje się że maksymalna liczba pudeł nie ma istotnego wpływu na zużytą pamięć. Za to wraz ze wzrostem iteracji, liniowo zwiększa się zużyta pamięć. Czynnikiem który istotniej wpływa na zużytą pamięć jest rozmiar planszy. Przeprowadzono eksperyment w którym dla 5 000 000 iteracji zbadano zużycie pamięci w zależności od rozmiaru analizowanej planszy. Jak widać na rys 3.6, ta zależność ma charakter wykładniczy i z uwagi na to, największy rozmiar planszy jaki udało się przeanalizować przy założonej liczbie iteracji to 17.

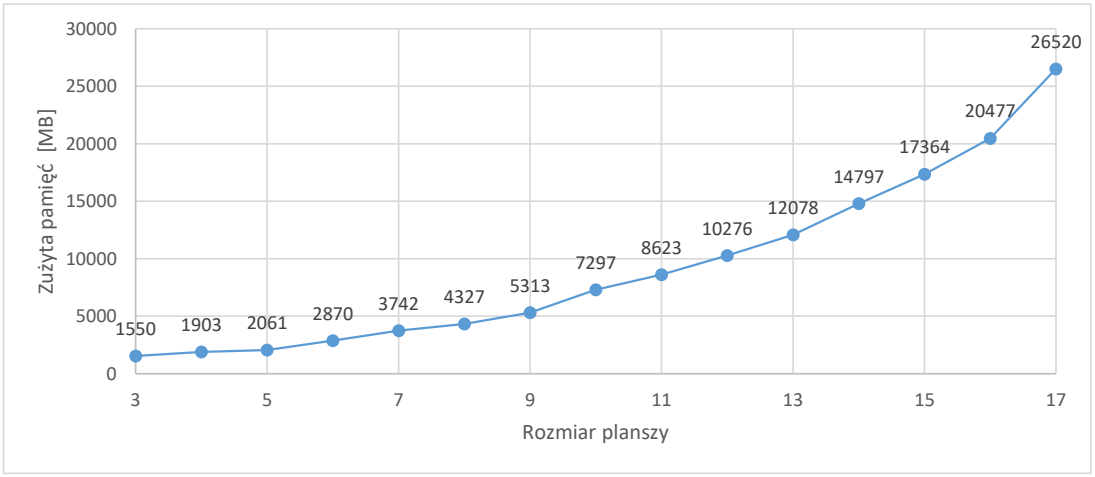

Rysunek 3.6: Zależność zużytej pamięci od rozmiaru planszy

3.4.3. Wypłaty

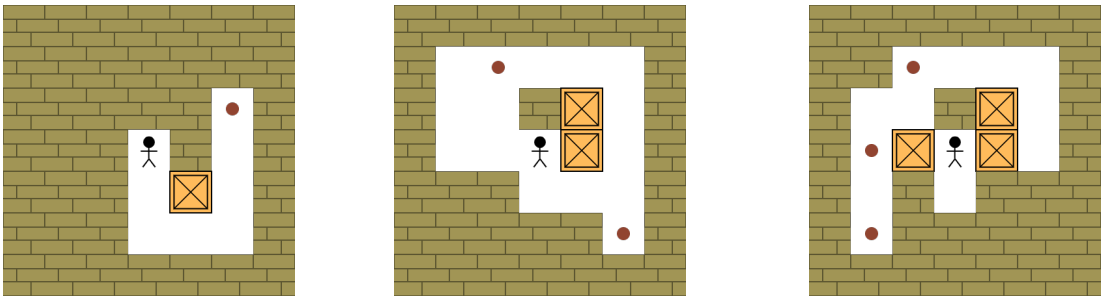

(a) Iteracje: 100, wypłata: 0.22 (b) Iteracje: 100000, wypłata: 0.62 (c) Iteracje: 10000000, wypłata: 1.1

Rysunek 3.7: Rozwój generowanych plansz wraz ze wzrostem iteracji

Wartość wypłaty za wygenerowany poziom podczas wykonania metody MCTS powinna być tym wyższa, im wygenerowana plansza jest bardziej skomplikowana. Przykładowy rozwój generowanych plansz wraz z wypłatami zaprezentowano na rys. 3.7. Postanowiono zbadać, jak zmienia się najwyższa wypłata podczas kolejnych iteracji. Poznanie tej zależności pozwoliłoby na odpowiednio wczesne przerywanie działania metody, w zależności od potrzeb. Jak widać na rys. 3.8, wartość maksymalnej wypłaty jest istotnie różna dla różnych rozmiarów plansz.

Autorzy metody MCTS podają za jej zaletę fakt, iż podczas jej działania niemal co każdą iterację generowana jest pewna plansza w wyniku losowej rozgrywki. W celu zweryfikowania użyteczności sekwencji generowanych plansz, dokonano analizy średnich wypłat dla algorytmu działającego przez milion iteracji. Wyniki analiz zaprezentowano na rys. 3.9. Jak widać, niecałe 20% generowanych plansz przekracza próg wypłaty 0.5, a jedynie 0.3% z nich jest ocenione na więcej niż 1.1. Prezentowany rozkład oznacza, że jedynie wąska podgrupa z generowanych plansz może być uznana za wystarczająco skomplikowaną.

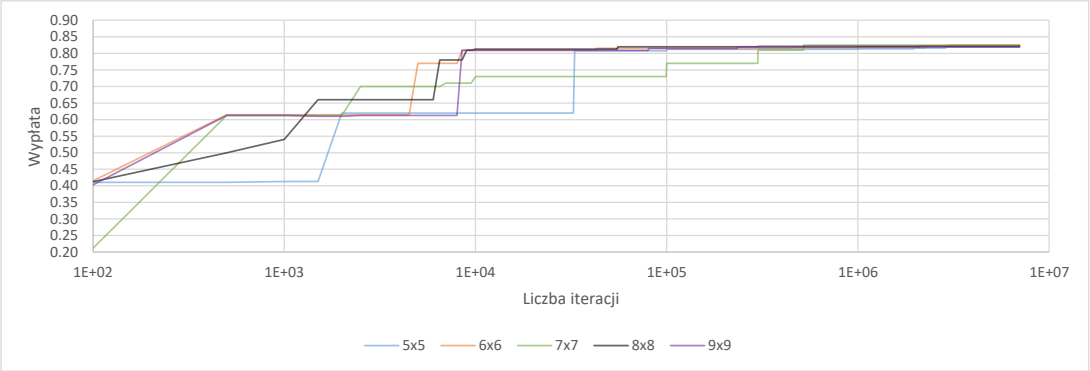

Rysunek 3.8: Zależność maksymalnej wypłaty od liczby iteracji

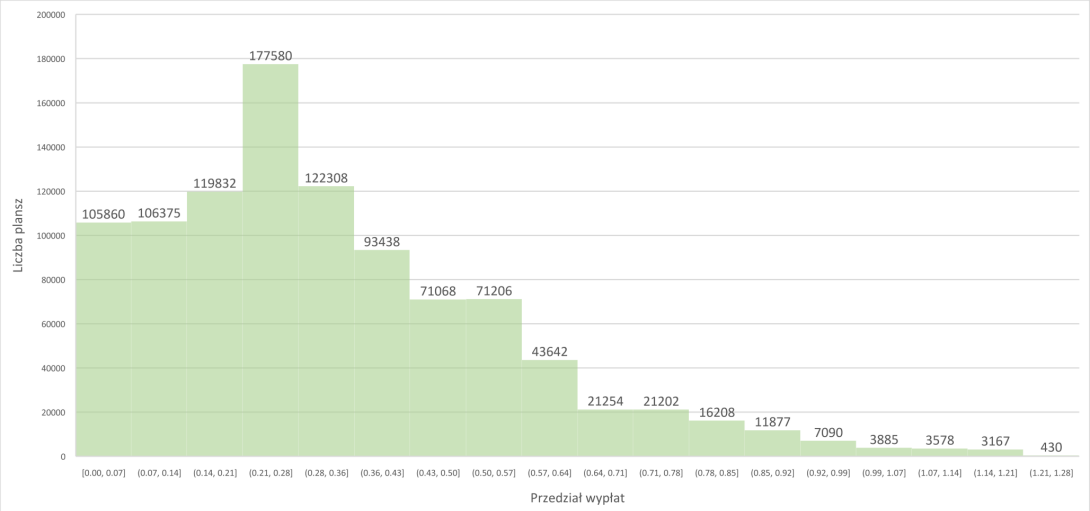

Rysunek 3.9: Rozkład wypłat dla generowanych plansz podczas miliona iteracji

3.5. Metoda PPO

Wszystkie eksperymenty zostały wykonane przy zachowaniu sugerowanych przez autorów [4] wartości hiperparametrów algorytmu PPO2, które wymieniono w tabeli 3.1. Wartości nagród wypłacanych agentom również bazowały na pracy [4], co wylistowano w tabeli 3.2.

Tabela 3.1: Użyte wartości hiperparametrów algorytmu PPO2

Nazwa parametru	**Wartość**
Gamma	0.99
Współczynnik entropii	0.01
Współczynnik uczenia	0.00025

Tabela 3.2: Nagrody wypłacane agentom podczas procesu treningu

Typ	**Wartość**
Poprawność poziomu	5
Obecność gracza	3
Poprawna liczba pudeł	2
Poprawna liczba pól docelowych	2
Poprawna proporcja pudeł	2
Długość rozwiązania	1

3.5.1. Poprawność plansz

Najistotniejszą różnicą między metodą PPO a pozostałymi prezentowanymi, jest ryzyko generowania niepoprawnych plansz. Przez planszę poprawną rozumie się planszę spełniającą poniższe warunki.

- Na planszy znajduje się dokładnie jeden gracz.
- Liczba pudeł odpowiada liczbie pól docelowych.
- Istnieje sekwencja ruchów gracza, która przekształca daną planszę w rozwiązaną planszę.

Wobec tego, istotne jest uczenie modeli generujących jak najwięcej poprawnych plansz, ponieważ tylko takie uznaje się za użyteczne. Zbadano zależność poprawności generowanych poziomów od liczby kroków agenta w procesie uczenia. Wyniki tych badań zobrazowano na rys.

3.10. Jak widać, dla agentów opartych o reprezentację wąską i żółwią, po wykonaniu 100 000 000 kroków poprawność utrzymuje się na poziomie 80 – 85%. Taką liczbę kroków maszyna opisana w rozdziale 3.1 uzyskuje po 10 godzinach treningu. Bazując na przeprowadzonych analizach, nie warto dalej trenować agentów opartych o te reprezentacje. Jednak w przypadku reprezentacji szerokiej, między dziesiątą a dziewiętnastą godziną treningu, średnia poprawność wzrosła z 56% do 68%, zachowując wciąż tendencję rosnącą. Te różnice można tłumaczyć przez większą przestrzeń dostępnych akcji reprezentacji szerokiej. Wyniki analiz pokryły się z badaniami przedstawionymi w [4].

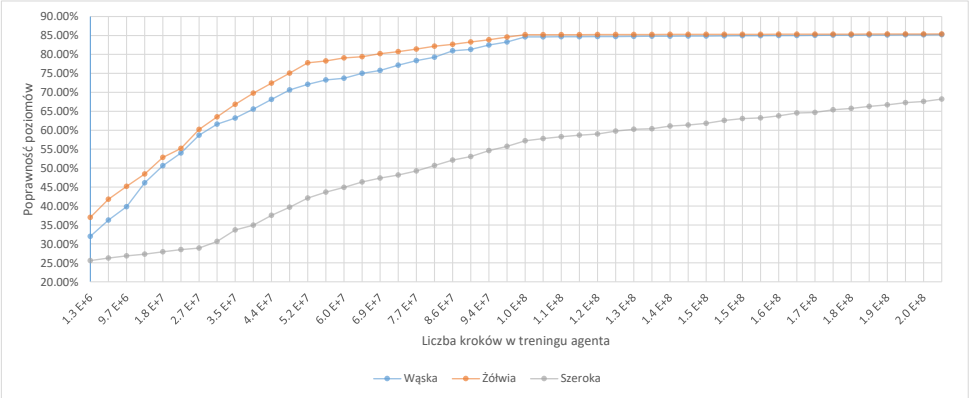

Rysunek 3.10: Zależność poprawności generowanych plansz od liczby kroków uczenia

3.5.2. Wydajność czasowa treningu

Opisywane w rozdziale 3.5.1 liczby kroków uczenia należy przełożyć na czas w celu zestawiania tej metody z innymi. Liczba kroków wykonywana w jednostce czasu jest stała podczas całego procesu uczenia i wynosi dla użytej maszyny 2777 kroków na sekundę. W związku z tym, uczenie agenta przez sto milionów kroków zajmuje niecałe dziesięć godzin, a przez dwieście milionów kroków – niespełna dziewiętnaście godzin. Przykłady plansz zewaluowanych dla agentów po stu i dwustu milionach kroków uczenia zaprezentowano odpowiednio na rys. 3.11 i 3.12.

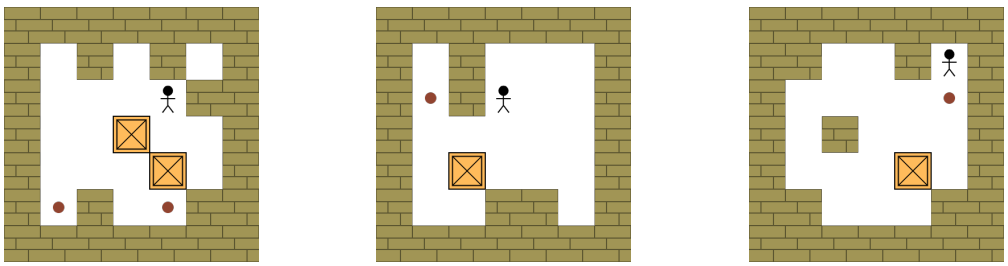

(a) Reprezentacja wąska (b) Reprezentacja żółwia (c) Reprezentacja szeroka

Rysunek 3.11: Plansze o najwyższych wypłatach dla agenta uczonego przez 9 godzin i 30 minut

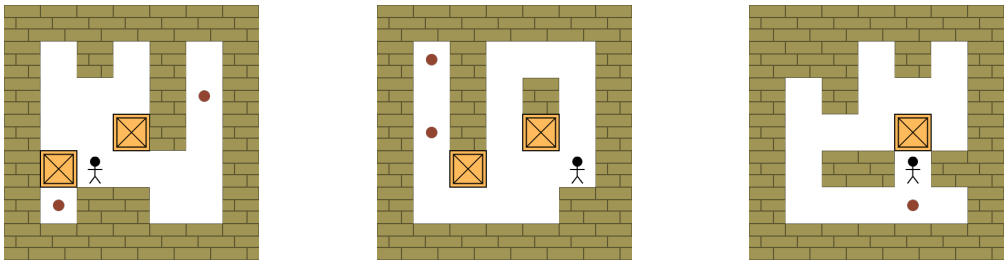

(a) Reprezentacja wąska (b) Reprezentacja żółwia (c) Reprezentacja szeroka

Rysunek 3.12: Plansze o najwyższych wypłatach dla agenta uczonego przez 19 godzin

3.5.3. Wydajność czasowa ewaluacji

W rozdziale 3.5.1 zbadano zależność długości treningu od poprawności generowanych plansz, wykazując że zadowalającą poprawność (powyżej 50%) utrzymuje się po około 110 minutach treningu dla reprezentacji wąskiej i żółwiej, a dla szerokiej – po 470. Jako że proces generowanie metody PPO opiera się ewaluowaniu uprzednio wytrenowanych agentów, postanowiono zbadać również czasy ewaluacji dla trzech zwracających najlepsze wyniki w zależności do rozmiaru planszy, dokonując tysiąckrotnej ewaluacji. Jak widać w tab. 3.3, średnie czasy ewaluacji nie przekraczają trzech sekund, a dla najmniejszych plansz – jednej.

Tabela 3.3: Średnie czasy ewaluacji w sekundach

Rozmiar	**Wąska**	**Żółwia**	**Szeroka**
4	0.2	0.1	0.1
5	0.2	0.3	0.3
6	0.8	0.6	0.6
7	1.4	1.3	1.2
8	2.3	2.0	2.1
9	2.2	2.9	1.3

Mimo iż średnie czasy ewaluacji wydają się być niskie, to metoda nie daje gwarancji tak szybkiej ewaluacji, co ukazano w tab. 3.4. Maksymalne czasy ewaluacji dla większych plansz (o rozmiarach 8 i 9) przekraczały 10 sekund, w jednym przypadku sięgając nawet 19.4s. Wyższe wartości średnie i maksymalne w przypadku reprezentacji szerokiej spowodowane są niższym skomplikowaniem generowanych plansz, które są szybciej weryfikowane przez *solver*.

Tabela 3.4: Maksymalne czasy ewaluacji w sekundach

Rozmiar	**Wąska**	**Żółwia**	**Szeroka**
4	0.2	0.2	1.1
5	1.2	3.4	0.6
6	2.2	1.6	0.7
7	8.6	5.9	5.6
8	19.4	9.6	7.3
9	15.2	12.7	10.9

3.5.4. Nagrody

W celu zbadania tempa uczenia, przeanalizowano uśrednione wypłaty dla agentów podczas procesu treningu. Na wyniki testów ukazane na rys. 3.13, nałożono linie trendu, które potwierdzają hipotezę z rozdziału 3.5.1 o wciąż trwającym procesie poprawy agentów z reprezentacją szeroką.

Podczas badania średnich nagród w procesie uczenia zauważono również iż ich rozkład jest zmienny w różnych etapach uczenia dla różnych reprezentacji. Po podzieleniu procesu uczenia na cztery równe fazy, stworzono wykres zmienności rozkładu średnich nagród z rys. 3.14. Jak widać, reprezentacja wąska i żółwia stabilizuje się w późniejszych fazach, zawężając tym samym rozkład otrzymywanych nagród. Reprezentacja szeroka, mimo tendencji wzrostowych, otrzymuje w każdej fazie coraz szerszy przedział średnich wypłat.

3.5.5. Rozmiar planszy

Wszystkie poprzednio opisane eksperymenty generowały plansze o rozmiarze $5x5$. Postanowiono jednak zbadać, jak metoda PPO radzi sobie z planszami większych rozmiarów. W tym celu wytrenowano dodatkowo osiemnastu agentów, z limitem na czas uczenia równym osiem godzin. Dla sześciu różnych rozmiarów plansz i trzech różnych reprezentacji dokonano później wielokrotnej ewaluacji w celu sprawdzenia średniej poprawności. Wyniki tego eksperymentu, ukazane na rys. 3.15, jasno wskazują na to, że metoda nie nadaje się dla plansz o rozmiarach większych niż $7x7$.

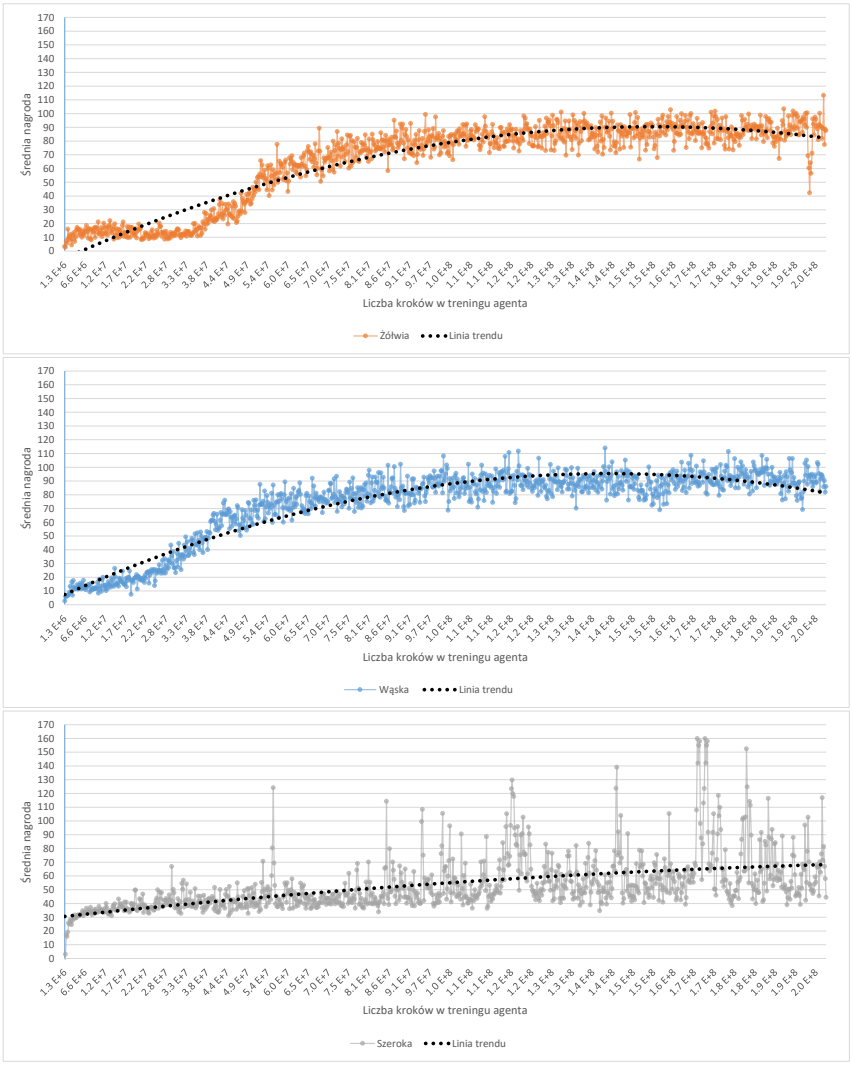

Rysunek 3.13: Zależność średniej nagrody od liczby kroków uczenia

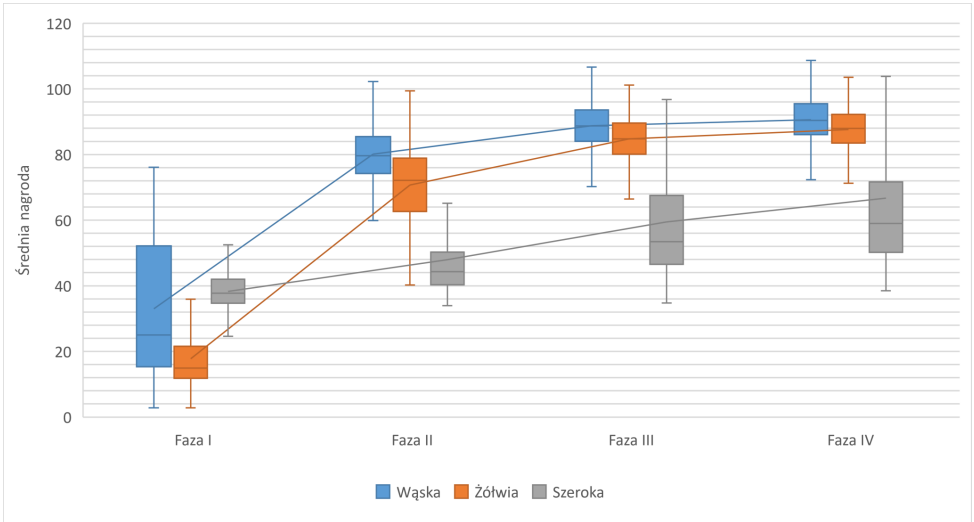

Rysunek 3.14: Rozkład średnich nagród w poszczególnych fazach uczenia

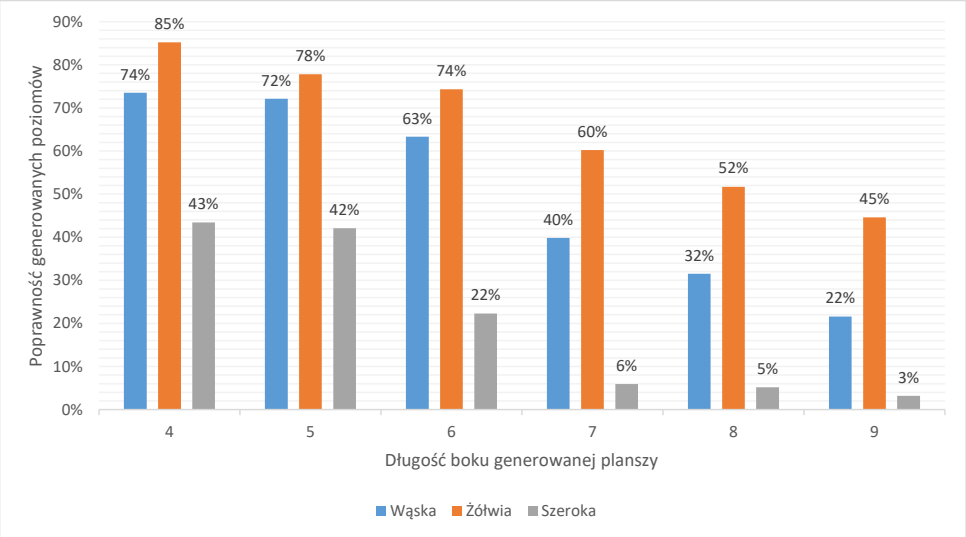

Rysunek 3.15: Zależność poprawności generowanych plansz od długości boku

3.6. Ogólne metryki

Jednoznaczne wyznaczenie jakości danej planszy *Sokoban* jest problemem, nad którym pochylają się twórcy generujących je metod, przykładowo w [23] i [24]. Im lepsza metryka oceniająca planszę, tym lepsze można dać wskazówki uczącemu się algorytmowi. Każda z prezentowanych metod wprowadza pewien sposób szacowania jakości generowanych plansz, jednak sposoby te są specyficzne dla każdej metody. W celu zestawienia wszystkich metod, wprowadza się dwie autorskie metryki, opisane w rozdziale 3.6.

Jak wykazano w [25], ludzka ocena skomplikowania planszy *Sokoban* najbardziej pokrywa się z metrykami bazującymi na rozwiązaniu optymalnym. Jak wspomniano w rozdziale 1.2.1, wyznaczenie jakiegokolwiek rozwiązania jest problemem *PSPACE*-zupełnym. Mimo, że metody takie jak SYM i MCTS symulują rozgrywkę, dostarczając tym samym pewne rozwiązanie planszy, to najczęściej odbiega ono istotnie od optymalnego. Wobec tego, wartości prezentowanych metryk wyznaczane są przy użyciu *solvera JSoko*.

Wyznaczono dwie metryki – PSH oraz LEN, faworyzujące odpowiednio plansze wymagające dużej liczby pchnięć oraz dużej liczby ruchów gracza. Metryka opisana wyrażeniem 3.1 to iloraz minimalnej liczby pchnięć i sumy długości boków planszy oraz kwadratu liczby pudeł. Z kolei druga, z równania 3.2 to iloraz minimalnej liczby ruchów i iloczynu długości boków planszy.

$$PSH = \frac{p}{w + h + b^2} \tag{3.1}$$

$$LEN = \frac{l}{w \cdot h} \tag{3.2}$$

Metryki zostały zaprojektowane tak, by zwracać najwyższe wyniki dla plansz uznawanych przez ludzi za najbardziej skomplikowane. Oznacza to, że muszą być niezależne od rozmiarów plansz, co zobrazowano na rys. 3.16, gdzie wartości obu metryk nie przekraczają 0.5.

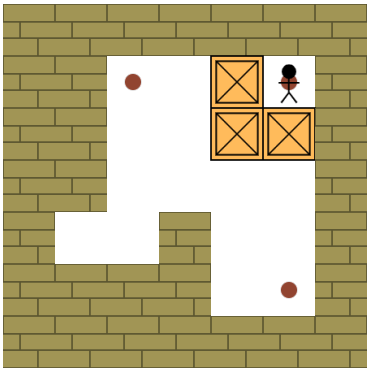

(a) Plansza 5x5 - $(0.36, 0.47)$

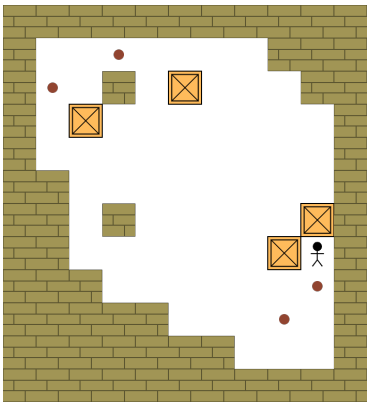

(b) Plansza 10x10 - $(0.25, 0.32)$

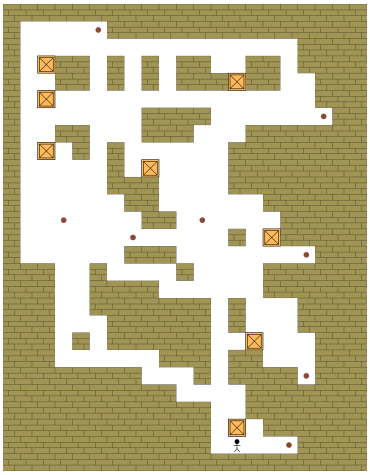

(c) Plansza 20x25 - $(0.44, 0.43)$

(d) Plansza 30x40 - $(0.28, 0.26)$

Rysunek 3.16: Przykłady mało skomplikowanych plansz wraz z wartościami metryk PSH i LEN

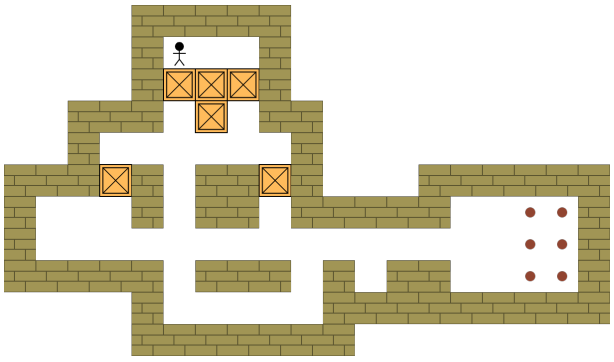

Rysunek 3.17: Plansza o wartościach metryk PSH=1.53 i LEN=1.38

3.7. Zestawienie metod

3.7.1. Wydajność czasowa

TODO - ile jakościowych w jakim czasie

3.7.2. Skomplikowanie

TODO - metryki

3.7.3. Wymagania sprzętowe

Każda z prezentowanych metod obarczona jest innymi ograniczeniami sprzętowymi. Metoda MCTS do swojego efektywnego działania potrzebuje operować na bardzo dużym drzewie rozgrywki, co pociąga za sobą istotne wymagania pamięciowe. Podobnie w metodzie PDB, która operuje na kolejce analizowanych stanów, wymagane jest odpowiednio dużo pamięci. W przypadku metody PPO należy wytrenować agentów przy odpowiednio dużej liczbie kroków uczenia, co jest kosztowne obliczeniowo. Metoda SYM ma najniższe wymagania sprzętowe z prezentowanych metod, ponieważ jej złożoność pamięciowa jest liniowa względem powierzchni generowanej planszy, a złożoność obliczeniowa – linowa względem zadanej liczby iteracji.

3.7.4. Rozmiar poziomu

Jak wykazały analizy prezentowane w rozdziałach 3.2-3.5 – metody heurystyczne są w stanie generować plansze o dostatecznym skomplikowaniu większe niż $6x6$. Metody oparte na uczeniu maszynowym wypadają w tej materii istotnie gorzej.

3.7.5. Kształt poziomu

Przez kształt poziomu rozumie się podzbiór ścian, które są ostatnimi istotnymi polami na planszy, co zobrazowano na rys. 3.18. Zgodnie z [23], najbardziej skomplikowane plansze *Sokoban* tworzone przez ludzi nie są kształtu prostokąta. Z prezentowanych metod jedynie SYM i PDB mogą tworzyć takie plansze, które są zadowalająco skomplikowane.

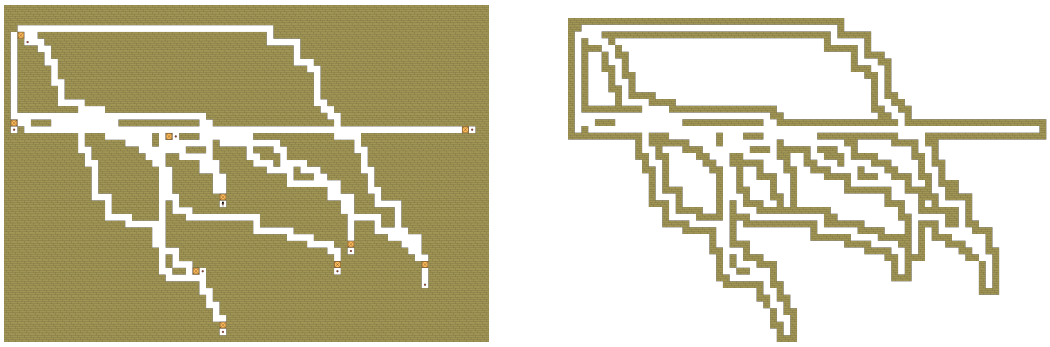

Rysunek 3.18: Plansza i odpowiadający jej kształt

3.7.6. Podsumowanie

Metodę SYM cechuje możliwość tworzenia plansz o bardzo dużych rozmiarach, tym samym kreowania kształtów plansz. Metoda PDB wypada najlepiej w kwestii tworzenia skomplikowanych poziomów średnich rozmiarów, jednak wymaga gotowego schematu planszy, na którym rozmieści pudła. Metody PPO i SYM specjalizują się w generowaniu skomplikowanych plansz małych rozmiarów. W ramach głębszej analizy problemu generowania plansz *Sokoban*, warto rozważyć metodę hybrydową, która mogłaby przy pomocy metody SYM generować duże poziomy, dzielić je na podproblemy rozwiązywane metodami MCTS/PPO i rozkładać finalne ułożenie pudeł przy pomocy metody PDB.

Jak wykazano w rozdziale 1.2.1, problem podania rozwiązania zadanej planszy jest skomplikowany obliczeniowo i nie znamy algorytmu wielomianowego rozwiązującego go. Korzystając z metod PPO i PDB, należy wziąć pod uwagę iż nie zwracają one przykładowego rozwiązania, w przeciwieństwie do SYM i MCTS. Większość tworzonych dziś aplikacji użytkowych, skupionych na grach łamigłówkowych, prezentuje wraz ze stawianymi wyzwaniami przykładowe rozwiązania.

Bibliografia

[1] Wu Yueyang, *An Efficient Approach of Sokoban Level Generation*, Graduate School of Computer and Information Science, Hosei University, Japan, 2020.

[2] Damaris S. Bento, Andre G. Pereira and Levi H. S. Lelis, *Procedural Generation of Initial States of Sokoban*, Federal University of Rio Grande do Sul, Federal University of Viçosa, Brazil, 2019.

[3] Bilal Kartal, Nick Sohre, and Stephen J. Guy, *Data-Driven Sokoban Puzzle Generation with Monte Carlo Tree Search*, University of Minnesota, United States, 2016.

[4] Ahmed Khalifa, Philip Bontrager, Sam Earle, Julian Togelius, *PCGRL: Procedural Content Generation via Reinforcement Learning*, New York University, United States, 2020.

[5] Steven James, George Konidaris, Benjamin Rosman, *An Analysis of Monte Carlo Tree Search*, University of the Witwatersrand, Johannesburg, South Africa.

[6] Francis Maes, Louis Wehenkel, Damien Ernst, *Automatic Discovery of Ranking Formulas for Playing with Multi-armed Bandits*, European Workshop on Reinforcement Learning, Athens, Greece, September 9–11, 2011.

[7] Jean-Yves Audibert, Remi Munos, Csaba Szepesvári, *Tuning Bandit Algorithms in Stochastic Environments*, Algorithmic Learning Theory 18th International Conference, Sendai, Japan, October 1–4, 2007.

[8] Levente Kocsis, Csaba Szepesvári, *Bandit based Monte-Carlo Planning*, European Conference on Machine Learning, Berlin, Germany, September 18–22, 2006.

[9] Joseph C. Culberson, Jonathan Schaeffer, *Searching with pattern databases*, Canadian Conference on Artificial Intelligence, pages 402—416, 1996.

[10] Florian Pommerening, Gabriele Roger, Malte Helmert, *Getting the most out of pattern databases for classical planning*, International Joint Conference on Artificial Intelligence, 2013.

[11] Ariel Felner, Richard E. Korf, Sarit Hanan, *Additive pattern database heuristics*, Journal of Artificial Intelligence Research, vol. 22, pp.279-–318, 2004.

[12] Erin J. Hastings, Ratan K. Guha, Kenneth O. Stanley, *Automatic Content Generation in the Galactic Arms Race Video Game*, IEEE Transactions on Computational Intelligence and AI in Games 1, vol. 4, pp. 245–263, 2010.

[13] Joseph C. Culberson, *Sokoban is PSPACE-complete*, 1997.

[14] Nir Lipovetzky, Hector Geffner, *Best-first width search: Exploration and exploitation in classical planning*, AAAI Conference on Artificial Intelligence, pp. 3590—3596, 2017.

[15] Walaa Baghdadi, Fawzya Shams Eddin, Rawan Al-Omari, Zeina Alhalawani, Mohammad Shaker, Noor Shaker *A Procedural Method for Automatic Generation of Spelunky Levels*, European Conference on the Applications of Evolutionary Computation, 2015.

[16] Vanessa Volz, Jacob Schrum, Jialin Liu, Simon M. Lucas, Adam Smith, Sebastian Risi, *Evolving Mario Levels in the Latent Space of a Deep Convolutional Generative Adversarial Network*, 2018.

[17] Nathan Brewer, *Computerized Dungeons and Randomly Generated Worlds: From Rogue to Minecraft*, Proceedings of the IEEE, vol. 105, no. 5, pp. 970–977, May 2017.

[18] Guy Davis, *Massive - Multiple Agent Simulation System in Virtual Environment*, 2003.

[19] Che Mat Ruzinoor, Abdul Rashid Mohamed Shariff, Biswajeet Pradhan, Mahmud Rodzi Ahmad, *A review on 3D terrain visualization of GIS data: techniques and software*, Geospatial Information Science, vol. 15:2, pp. 105–115, 2012.

[20] Karman, S.J. *Generating Sokoban Levels that are Interesting to Play using Simulation*, Utrecht University, 2018.

[21] Mnih V., Kavukcuoglu K., Silver D., Rusu A. A., *Humanlevel control through deep reinforcement learning.* Nature 518(7540), 2015.

[22] Earle S., *Using fractal neural networks to play simcity 1 and conways game of life at variable scales*, AIIDE Workshop on Experimental AI in Games, 2019.

[23] Petr Jarušek, Radek Pelánek, *Difficulty rating of sokoban puzzle*, STAIRS 2010, IOS Press, pp. 140–150, 2010.

[24] Petr Jarušek, Radek Pelánek, *Human problem solving: Sokoban case study*, Faculty of Informatics Masaryk University, Brno, 2010.

[25] Petr Jarušek, Radek Pelánek, *What Determines Difficulty of Transport Puzzles?*, XXIV International FLAIRS Conference, Florida, USA, 2011.

[26] *Sokoban* wiki: http://www.sokobano.de/wiki.

[27] Joshua Taylor, Ian Parberry, *Procedural generation of Sokoban levels*, Technical Report LARC, Laboratory for Recreational Computing, University of North Texas, 2011.

Wykaz najważniejszych oznaczeń i skrótów

- **MCTS** – Monte Carlo Tree Search
- **UCT** – Upper Confidence Bound Applied to Trees

Spis rysunków

Spis tabel

Spis załączników

1. Płyta CD zawierająca:
    - dokument z treścią pracy dyplomowej,
    - streszczenie w języku polskim,
    - streszczenie w języku angielskim,
    - kod programów.